CC0F4 · EXAMEN PARCIAL · SEMANAS 1 A 7

Del prototipo LLM a un sistema RAG evaluable

Riesgo de mercado con evidencia: tres recuperadores comparados, respuestas con citas auditadas y una herramienta con contratos.

DOCUMENTOS	PASSAGES	CONSULTAS	EXPERIMENTOS	CASOS PC1
21	150	22 + 3	3	8/8
Fed, BIS y Wikipedia	extractos textuales	con y sin evidencia	recuperación · RAG · herramienta	reproducidos por la herramienta

Pedro Lautaro Quispe Ballesteros

Tópicos de Ciencia de la Computación I · 2026-2 · 29 de octubre de 2026

Una alerta de riesgo necesita evidencia que se pueda verificar

La pregunta es la misma desde la PC1. Lo que cambia es cuánto se puede medir de la respuesta.

PC1 · SEMANAS 1–3

El LLM no aplica la regla

Qwen de 0,5B dijo «low» en los 8 casos, incluido el crash del COVID. Lección: el cálculo va en código.

→ Experimento 3

PC2 · SEMANAS 3–4

La recuperación se sesga

Con 8 documentos y 6 consultas, un solo documento acaparaba el ranking de la consulta Q01.

→ Experimento 1

PARCIAL · SEMANAS 1–7

Medir con datos reales

Benchmark nuevo, tres recuperadores, respuestas RAG auditadas y una herramienta con contratos.

→ Experimentos 1, 2 y 3

PC1 · ACCURACY

0,375

igual a responder siempre «low»

PC2 · RECALL@3

0,833

solo 6 consultas y 8 resúmenes propios

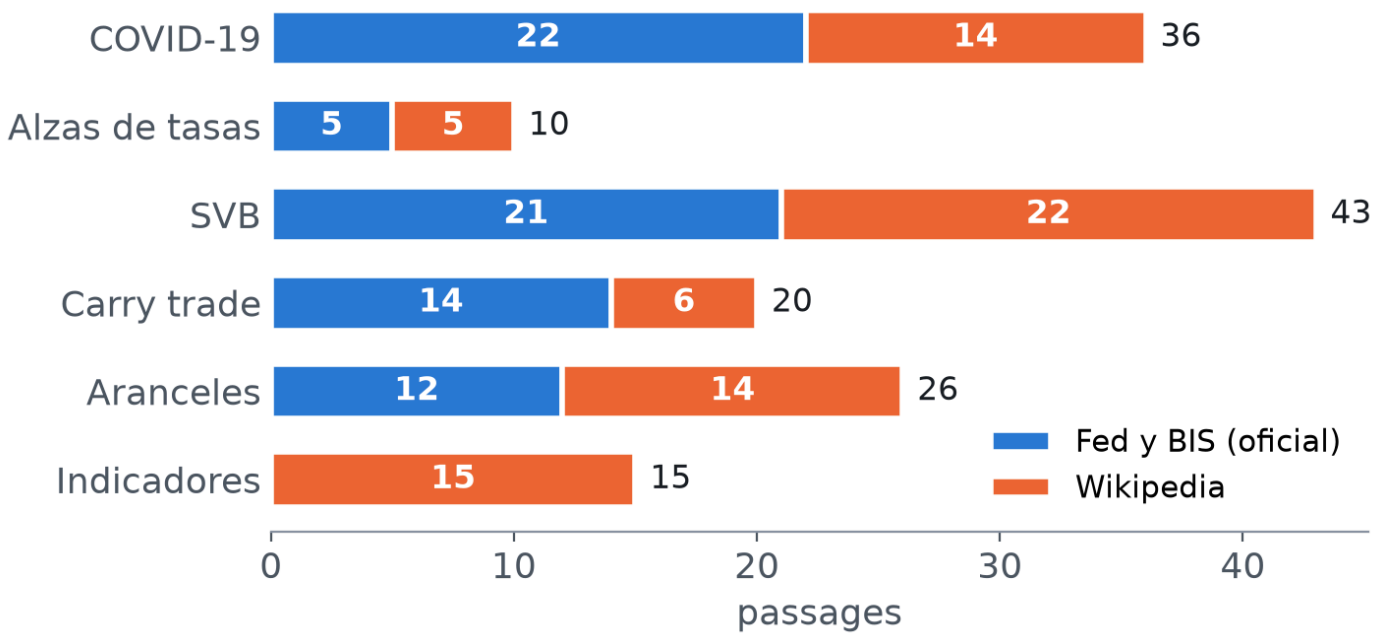
PARCIAL · BENCHMARK

22 · 150

consultas · passages reales

Sin agentes: esta es la base sobre la que se construirán en la Semana 9.

150 passages reales de los mismos episodios de la PC1



EL BENCHMARK

21 documentos en inglés: comunicados e informes de la Fed, dos publicaciones del BIS y artículos de Wikipedia con la versión fijada.

22 consultas y 57 pares consulta–passage relevante (los *qrels*), anotados **antes** de correr cualquier sistema.

3 consultas más **sin respuesta** en el corpus, para probar si el sistema sabe abstenerse.

Cada semana tiene una salida concreta en el cuaderno

semana	concepto	evidencia en el cuaderno
1	tokens, Q/K/V, máscara causal	cambiar el último token deja los logits previos iguales (diferencia 0,0)
2	logits, softmax, greedy, KV cache	greedy elige el argmax (prob. 0,62); el KV cache acelera ×3,8
3	JSON Schema: válido no es adecuado	25/25 consultas válidas, pero 20/25 copian la original
4	chunking, FAISS, top-k, qrels	102 chunks; sistema A como línea base
5	BM25, fusión RRF, Cross-Encoder	comparación A, B y C con bootstrap
6	contratos, reintentos, timeouts	16/16 escenarios correctos; 8/8 casos de la PC1
7	Recall, MRR, nDCG, grounding	auditoría de respuestas, citas y afirmaciones

La matriz completa (recurso del curso, celda, evidencia y limitación) está en el README.

Tres formas de buscar la evidencia, sobre las mismas 22 consultas

A · LÍNEA BASE

Densa

e5 convierte texto en vectores y FAISS trae los más parecidos en significado.

B = A +

BM25 + RRF

Suma una búsqueda por palabras exactas y fusiona los dos rankings por posición.

C = B +

Cross-Encoder

Relee consulta y texto juntos y reordena los 10 mejores candidatos.

CÓMO SE MIDE

Recall@k: qué parte de la evidencia relevante aparece entre los k primeros.

MRR: qué tan arriba sale el primer passage relevante.

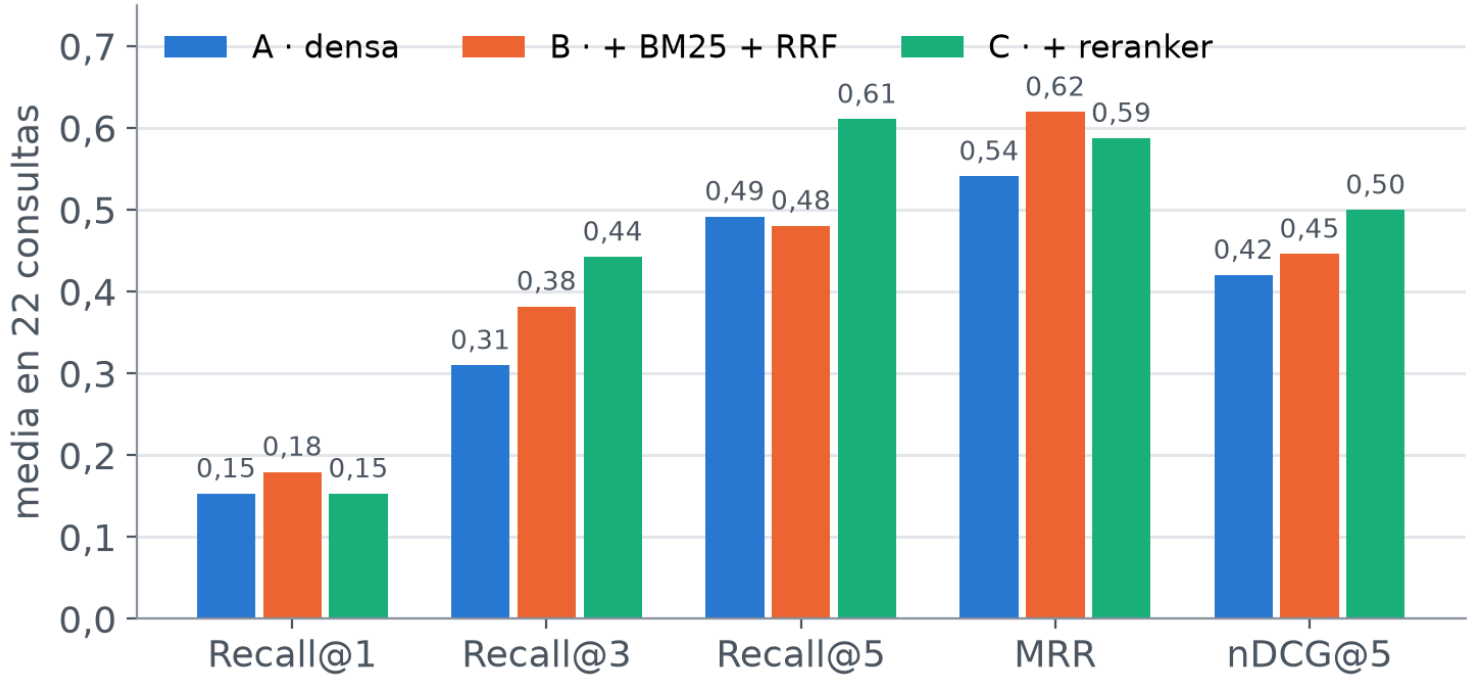
nDCG@5: calidad del orden en los 5 primeros.

QUÉ QUEDA FIJO

Corpus, consultas, qrels, chunks de 180 palabras, 10 candidatos y semilla 42.

De A a B cambian dos cosas a la vez; de B a C solo una, el reranker.

Cada etapa sube el Recall@3, pero el orden no siempre mejora

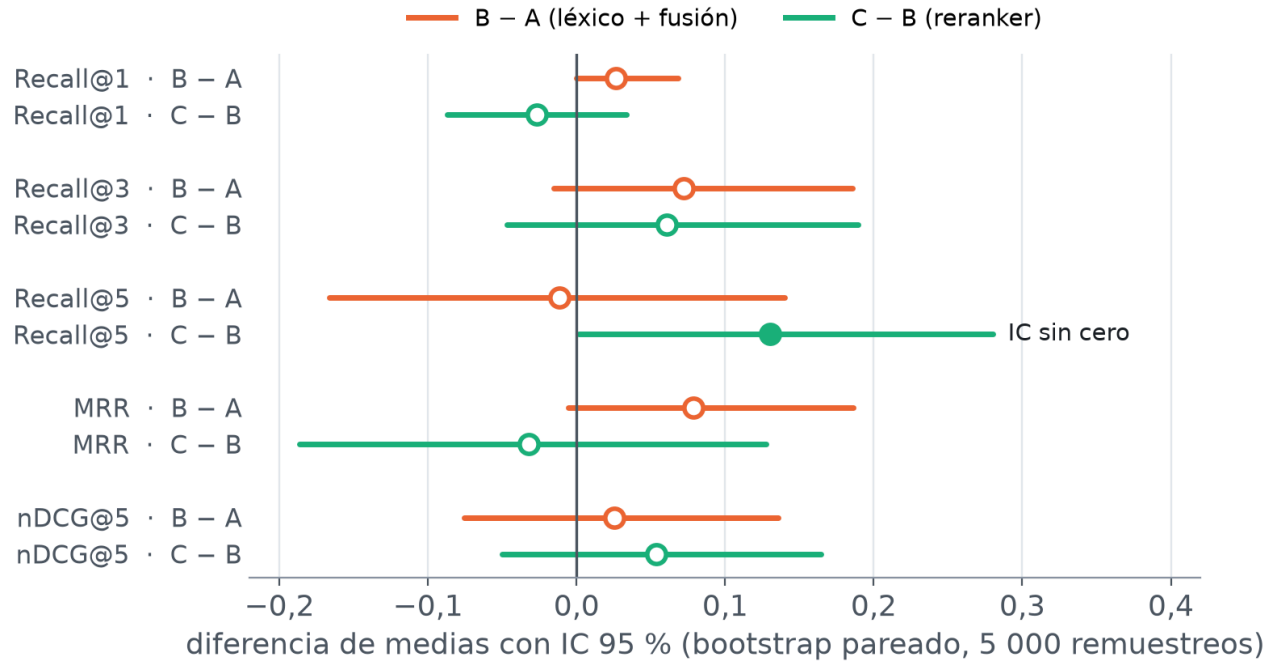


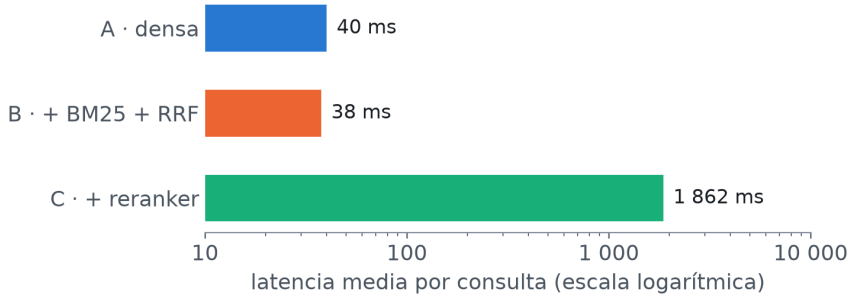
Recall@3 pasa de **0,310** a **0,382** y a **0,442**.

El reranker sube Recall@5, pero **baja el MRR** respecto de B.

BM25 solo llega a 0,352 en Recall@3, más que la densa sola.

Con 22 consultas casi ninguna diferencia supera al azar





Solo un intervalo deja fuera el cero: Recall@5 de C sobre B (+0,130; de 0,002 a 0,280).

Y el reranker cuesta unas **46 veces más** por consulta.

Densa y BM25 fallan en consultas distintas

	A	B	C	BM25
Q01 · easy	0	0	0	0
Q02 · medium	0,25	0,50	0,50	0,50
Q03 · hard	0,40	0,40	0,20	0,40
Q04 · hard	0,33	0,33	0,33	0,33
Q05 · easy	1	1	1	0
Q06 · medium	0,25	0,25	0,25	0,25
Q07 · medium	0	0	0	0
Q08 · hard	0	0	0	0
Q09 · medium	0	0	0	0
Q10 · medium	0,50	0,50	0,50	0,50
Q11 · hard	0	0	0,20	0
Q12 · hard	0	1	1	1
Q13 · medium	0	0,33	0	0,67
Q14 · easy	0,50	0,50	1	0,50
Q15 · hard	0	0,33	0,67	0,33
Q16 · medium	1	1	0,50	1
Q17 · hard	0,50	0,50	0,50	0,50
Q18 · hard	0,75	0,75	0,75	0,75
Q19 · easy	0	0	0	0
Q20 · medium	0	0	1	0
Q21 · medium	0,67	0,33	0,67	0,33
Q22 · medium	0,67	0,67	0,67	0,67

Q01 · NADIE LA RECUPERA

Pregunta por el «VIX». La evidencia dice «CBOE Volatility Index» y nunca usa esa sigla, así que BM25 no la encuentra; otros documentos que sí dicen «VIX» la desplazan.

El reranker no ayuda: solo reordena candidatos, y esta evidencia nunca fue candidata.

LAS DOS SEÑALES SE COMPLEMENTAN

Q05: «cuánto cayó desde su máximo» no comparte palabras con «drawdown». BM25 falla y la densa acierta.

Q12 y Q13: siglas y términos exactos como «EGRRCPA». La densa falla y BM25 acierta.

Q20: solo C la resuelve, porque sube el chunk correcto al primer lugar.

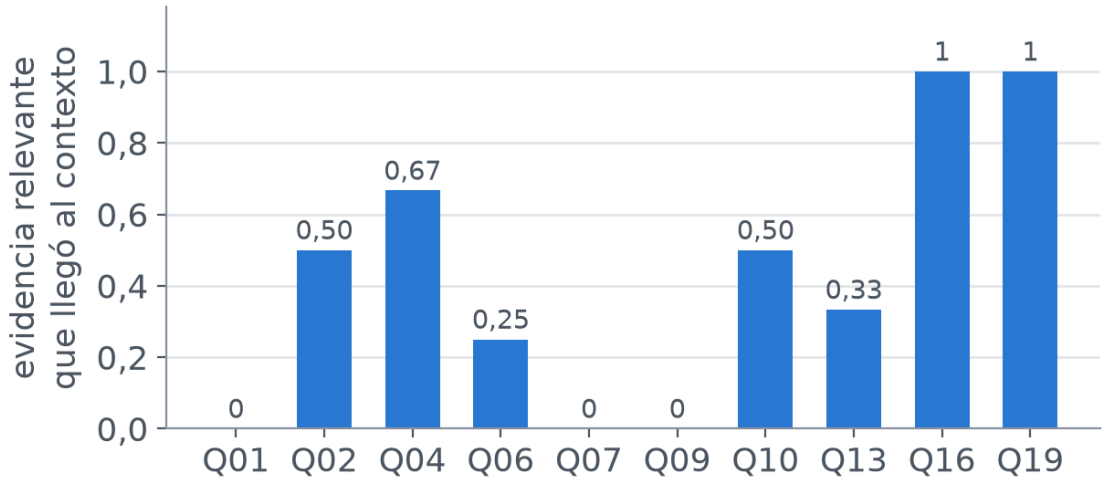
El mismo modelo responde dos veces: sin evidencia y con evidencia

DISEÑO

Qwen de 0,5B, decodificación greedy y **13 preguntas fijas**: 10 con respuesta en el corpus y 3 sin ella.

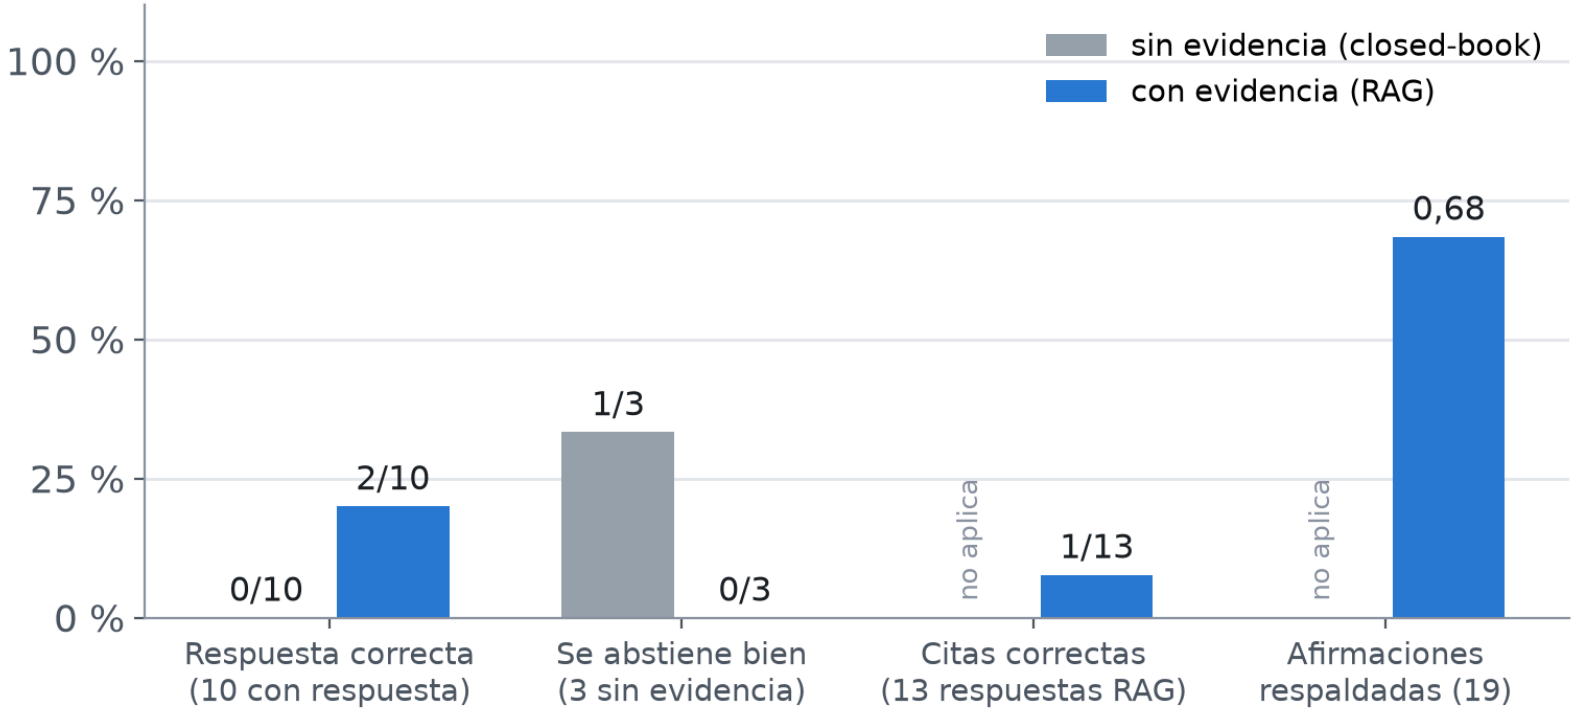
Sin evidencia: responde de memoria. **Con evidencia**: recibe los 3 mejores chunks del sistema C y debe citar los passages.

Se audita a mano, por separado: si la respuesta es correcta, si la cita es correcta y si cada afirmación está respaldada.



Antes de mirar al modelo: la evidencia completa llegó al contexto solo en Q16 y Q19. En Q01, Q07 y Q09 no llegó nada.

Con evidencia acierta más, pero cita mal y ya no se abstiene



Correctas: **0/10** sin evidencia y **2/10** con evidencia.

Citas correctas: solo **1 de 13**.

El 68 % de lo que afirma está en el contexto, pero muchas veces **copia un texto que no responde** la pregunta.

Tres fallos distintos de la misma respuesta con evidencia

Q07 · INVENTA

`«[D01-P02] Nathan Sheets dissented at the March 2020 emergency meeting…»`

El contexto no traía el passage correcto. Quien votó en contra fue **Loretta Mester** (D10-P05).

Q19 · CITA MAL

`«[D05-P05] The S&P 500 rose 9.52% for its biggest one-day gain since 2008.»`

La cifra es correcta, pero está en **D05-P13**. Que haya cita no significa que sea la correcta.

N01 · NO SE ABSTIENE

`«[D06-P05] 2008 – On March 9, 2008, the VIX hit 62.12…»`

No había respuesta en el corpus. Copió un passage de 2020 y **cambió el año** a 2008.

Sin evidencia, el mismo modelo dijo «I don't know» en 5 de las 10 preguntas con respuesta e inventó que el VIX llegó a «≈150» en 2008.

Con la misma evidencia, el anexo con DeepSeek sí se abstiene en las 3 sin respuesta: el cuello de botella de Qwen está en la generación.

Un cálculo de riesgo que falla de forma controlada

`risk.compute_signal(ticker, fecha)` calcula los indicadores y la severidad con la regla de la PC1.

1 · ENTRADA
¿Formato válido?
Pydantic revisa tipos, patrón y campos.

→

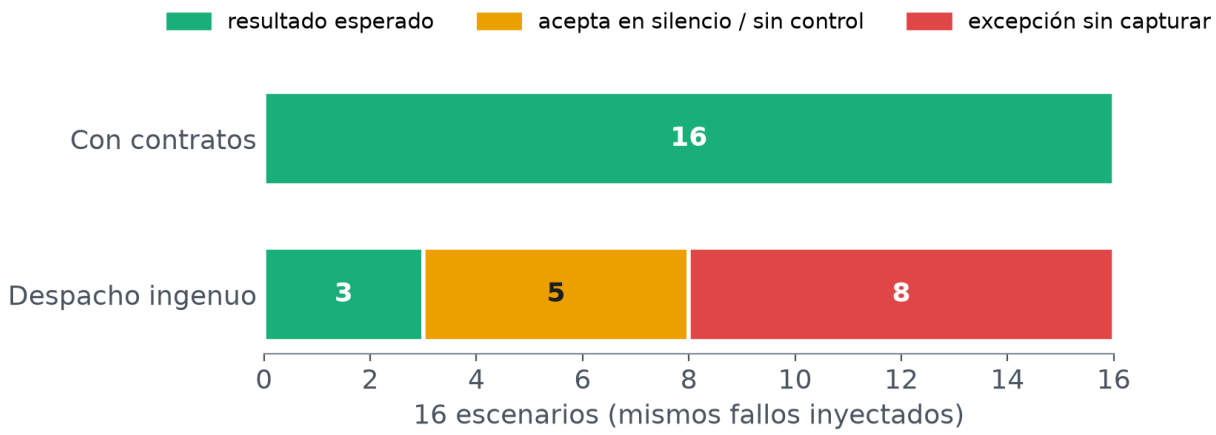
2 · DOMINIO
¿Existe?
Ticker soportado y día de negociación.

→

3 · EJECUCIÓN
Reintento y límite
Solo reintenta fallos temporales.

→

4 · SALIDA
¿Respeta lo prometido?
Resultado o error con tipo.



Reproduce los **8 de 8** casos de la PC1 y pasan las 28 pruebas.

Un error de formato o de dominio **no se reintenta**: repetir da el mismo error.

Lo que muestran los datos, y lo que no se puede afirmar

LO QUE MUESTRAN

BM25 y la búsqueda densa se complementan; ningún sistema domina en 22 consultas.

Dar evidencia a un modelo de 0,5B no lo vuelve fiel: acierta más, pero cita mal y no se abstiene.

El cálculo de indicadores debe hacerse en código con contratos, no en el LLM.

LÍMITES

22 consultas, un solo anotador, 4 chunks truncados y un solo modelo generador.

La comparación por chunk se añadió después de ver los resultados.

No puedo afirmar que C sea mejor que B ni que el reranker justifique su costo.

Siguiente paso (Semana 9): workflows y agentes sobre esta base reproducible.