CC0F4 · EXAMEN PARCIAL · SEMANAS 1 A 7

Del prototipo LLM a un sistema RAG evaluable

Recuperación híbrida, respuestas con citas y una herramienta con contratos, medidas sobre documentos reales de riesgo de mercado.

DOCUMENTOS	PASSAGES	CONSULTAS	SISTEMAS	HERRAMIENTA
21	150	22+3	A · B · C	8/8
Fed, BIS, Wikipedia	extractos textuales	con y sin evidencia	densa · híbrida · reranker	casos de la PC1 reproducidos

Pedro Lautaro Quispe Ballesteros

Tópicos de Ciencia de la Computación I · 2026-2 · 29 de octubre de 2026

La misma pregunta de la PC1 y la PC2, ahora con evidencia y medición

¿Qué evidencia sustenta una alerta de riesgo de mercado, y cómo sé que funciona?

PC1

El LLM no calcula

Qwen 0,5B dijo «low» en 8 de 8 casos. Los indicadores deben calcularse con código.

→ herramienta (Exp. 3)

PC2

Un documento acapara

Recuperación densa sobre 8 documentos y 6 consultas; la consulta Q01 quedaba desplazada.

→ BM25 + reranker (Exp. 1)

PARCIAL

Evaluar de verdad

Documentos reales, qrels fijados antes de comparar, RAG con citas auditado y errores a la vista.

→ Exp. 1, 2 y 3

No hay agentes: se construye y mide la base que los agentes necesitarán desde la Semana 9.

Datos reales y qrels fijados antes de comparar sistemas

Episodios de la PC1 (COVID, tasas 2022, SVB, carry trade, aranceles) en documentos oficiales en inglés.

FLUJO DEL EXPERIMENTO 1 Y 2

A
e5 + FAISS
significado

→

B
+ BM25 + RRF
palabras + fusión

→

C
+ Cross-Encoder
reordena 10

top-3 → respuesta con citas → auditoría de respuesta, citas y grounding.

DOCUMENTOS
21
8 Wikipedia · 8 Fed · 3 informes · 2 BIS

PASSAGES
150
textuales, con id

CONSULTAS
22
+3 sin evidencia

CHUNKS
102
180 palabras, overlap 1

DISTRACTORES PROPIOS DE LAS FUENTES (NO CREADOS DESPUÉS DE VER RESULTADOS)

- comunicados FOMC casi idénticos (D12 a D15)
- hechos de SVB repetidos en 4 documentos
- «CBOE Volatility Index» ≠ «VIX» (Q01)
- 3 consultas sin respuesta en el corpus

Cada semana deja una evidencia que se puede abrir en el cuaderno

sem.	concepto	evidencia
S1	tokens, Q/K/V, máscara causal	`diferencia 0,0 al cambiar el último token`
S2	logits → softmax → greedy, KV cache	`greedy = argmax; caché más rápido`
S3	JSON Schema, válido ≠ adecuado	`25/25 válidas, 20/25 copian Q0`
S4	chunking, FAISS, top-k, qrels	`102 chunks, 4 truncados`
S5	BM25, RRF, Cross-Encoder	`A/B/C con bootstrap`
S6	contratos, retry, timeout	`16/16 escenarios, 8/8 casos PC1`
S7	Recall, MRR, nDCG, grounding	`errores Q01, Q07, Q19`

Matriz completa con recurso, celda, evidencia y limitación en el README.

Ninguna configuración domina, y el reranker cuesta 46 veces más

RECALL@3 (22 CONSULTAS)



	R@5	MRR	nDCG@5	latencia
A	0,492	0,541	0,420	40 ms
B	0,480	0,619	0,446	38 ms
C	0,611	0,587	0,500	1,862 ms

CÓMO LEERLO

A → B suma BM25 *y* fusión: no se atribuye a una sola.

B → C aísla el reranker: sube Recall@5 pero baja el MRR.

Bootstrap: solo Recall@5 de C sobre B excluye el cero (0,130; IC 0,002 a 0,280).

BM25 solo: R@3 0,352

La evidencia quita el «no sé», pero no garantiza respuestas fieles

QWEN 0,5B · MISMAS 13 PREGUNTAS · COMPROBACIÓN MECÁNICA

	closed-book	con RAG
abstiene (10 respondibles)	5	0
abstiene (3 sin evidencia)	1	**0**
respuestas con cita	0	7
ids citados en los qrels	–	0,29

AUDITORÍA MANUAL

	closed-book	RAG
respuesta correcta	0/10	2/10
abstención adecuada	1/3	0/3
citas correctas	–	1/13
afirmaciones respaldadas	–	0,68

TRES FALLOS DISTINTOS

Q07 · alucina. Sin la passage correcta inventa que «Sheets disintió» (fue Mester).

Q19 · cita mal. Dice 9,52 % (correcto) pero cita `D05-P05`; está en `D05-P13`.

N01–N03 · no se abstiene. Reescribe un passage cambiando 2020 por 2008.

El contexto cubre toda la evidencia solo en 2 de 10 preguntas.

Los contratos convierten los fallos en datos que se pueden decidir

`risk.compute_signal(ticker, fecha)`: indicadores y severidad con la regla de la PC1.

1 · ENTRADA
Pydantic
tipos, patrón, sin campos extra
`validation`

→

2 · DOMINIO
¿existe?
ticker, día de negociación, historia
`domain`

→

3 · EJECUCIÓN
retry + timeout
solo transient y timeout
`deadline 2 s`

→

4 · SALIDA
contrato
ToolResult o ToolError
`output_contract`

ESCENARIOS	CASOS PC1	EXCEPCIONES SIN CAPTURAR	PRUEBAS
16/16	8/8	0 vs 8	28
resultado esperado	reproducidos exactos	contratos vs ingenuo	pytest, todas pasan

CUÁNDO REINTENTAR

`transient → sí` `timeout → si hay tiempo` `validation → no` `domain → no` `output_contract → no`

Reintentar no es reparar: repetir la misma llamada no corrige un argumento mal formado.

Lo que sé, lo que no sé y lo que sigue

EL ERROR QUE NADIE ARREGLA (Q01)

Pregunta por el **VIX**; la evidencia dice «CBOE Volatility Index». Ningún sistema trae ese chunk al top-10.

El reranker solo reordena candidatos: lo que no es candidato no se rescata.

CONCLUSIONES ACOTADAS

BM25 y densa son **complementarias**; con 22 consultas no hay ganadora clara.

Evidencia ≠ fidelidad: con 0,5B el límite es el generador y la cobertura.

Los indicadores van en código con contratos, no en el LLM.

LÍMITES

22 consultas · 1 anotador · 4 chunks truncados · 1 modelo de 0,5B.

Un diagnóstico por chunk se añadió *después* de ver resultados.

Semana 9: workflows y agentes sobre esta base.

LO QUE DEJA EL REPOSITORIO

- baseline reproducible
- corpus y qrels trazables
- recuperación comparada
- RAG evaluado
- herramienta con contratos