CC0F4 · TÓPICOS DE CIENCIA DE LA COMPUTACIÓN I · PRÁCTICA CALIFICADA 2

De una consulta estructurada a recuperación densa verificable

Vigilante de riesgo de mercado: un LLM convierte una necesidad en JSON validado, e5-small la busca en FAISS y se mide si la evidencia aparece en los primeros resultados.

CORPUS	CONSULTAS	ENCODER	ÍNDICE	EXPERIMENTOS
8 · 50	6	e5-small	FlatIP	2
documentos · passages	con qrels por passage	384 dim · query: / passage:	exacto · L2-normalizado	consulta, chunking

Pedro Lautaro Quispe Ballesteros

PC1_Topicos1 / pc2

¿Qué evidencia necesito antes de emitir una alerta?

La PC1 mostró que el modelo no clasifica bien una señal (dijo `low` en los 8 casos). Antes de pensar en RAG hay que saber si el recuperador encuentra el texto que sustenta una alerta.

NECESIDAD DE INFORMACIÓN (Q04)

«¿Qué hizo la Reserva Federal con las tasas de interés para responder al pánico por el coronavirus?»

EVIDENCIA RELEVANTE (QRELS)

D08-P01 FOMC 15-mar-2020: rango a 0 %–0,25 %
D01-P06 crónica del crash: recorte de 50 pb y 0–0,25 %

LO QUE CONSTRUYO

```
necesidad
 → LLM → JSON validado
 → embedding (e5-small)
 → FAISS IndexFlatIP
 → top-k → Recall@k
```

Lo recuperado **no** se usa todavía para generar una respuesta.

8 documentos públicos, 6 necesidades, evidencia marcada por passage

8 documentos · 50 passages · 2.101 palabras | Wikipedia · Fed · AP | resumidos en español por mí | fijados antes de ejecutar

id	necesidad de información (Q0)	dificultad	passages relevantes
Q01	volatilidad esperada en el peor día de la crisis COVID	easy	D01-P05 · D05-P05
Q02	por qué SVB no resistió con tanta cartera de bonos	medium	D02-P02 · D02-P03
Q03	pedir prestado en moneda barata y ventas masivas de golpe	hard	D03-P02 · D03-P03
Q04	qué hizo la Fed con las tasas ante el pánico por el coronavirus	ambiguous	D08-P01 · D01-P06
Q05	cómo se mide la caída desde el máximo reciente	easy	D06-P01 · D06-P02
Q06	reacción de los bonos del Tesoro ante los aranceles de abril 2025	medium	D04-P05

Los qrels van sobre **passage_id**, no sobre chunks: no cambian cuando cambia la segmentación. D01 y D08 hablan del mismo mes; D02 y D07, de alzas de tasas: vecinos confusos a propósito.

De la pregunta al top-k, cada paso se puede inspeccionar

SEMANA 3
LLM
Qwen2.5-0.5B
greedy

→

SEMANA 3
JSON Schema
query · intent · abstain

→

SEMANA 4
chunks
passages + overlap 1

→

SEMANA 4
e5-small
query: / passage:

→

SEMANA 4
IndexFlatIP
top-k

SE MIDE
parseable · schema_valid_rate

SE VERIFICA
validación contra el schema

SE CONTROLA
target_words, ≤ 512 tokens

SE COMPRUEBA
norma = 1 · coseno = IP

SE MIDE
Recall@1 / 3 / 5

Dos experimentos, una variable cada uno: **Exp. 1** cambia la consulta (Q0 vs Q1) · **Exp. 2** cambia el tamaño del fragmento (100 / 180 / 320 palabras). Todo lo demás permanece fijo.

Tres niveles: parseable, schema-valid, adecuada

PROMPT (SEPARA INSTRUCCIÓN, ENTRADA, CONTRATO)

```
TAREA   reformula, no respondas
NECESIDAD  {need}
CONTRATO  query · intent · abstain
          «sin Markdown»
```

SCHEMA 2020-12

```
query: string 8–200
intent: enum[5] · abstain: boolean
additionalProperties: false
```

RESULTADO CON QWEN2.5-0.5B, GREEDY (6 NECESIDADES)

parseable	**6 / 6**
JSON exacto (sin cerca ```)	**0 / 6**
schema-valid	**5 / 6** = 0.833
abstain = true	0

Q03 inventó `policy_response` y `other` y omitió `abstain`: JSON legible, schema roto.

Adecuada = ¿conserva lo que yo quería buscar? No la decide el schema: la mide la recuperación. Aquí `intent` fue `risk_event` en las 5 válidas, también para Q04 (política monetaria) y Q05 (indicador).

Coseno e producto interno coinciden si los vectores son unitarios

MULTILINGUAL-E5-SMALL · 384 DIM · 512 TOKENS

```
"query: ¿Qué hizo la Fed…"
"passage: El 15 de marzo de 2020…"
```

Los prefijos son parte de la interfaz del modelo.

NORMALIZACIÓN Y SIMILITUD

$$\hat{x}^T\hat{y} = \cos(x, y) \quad si \ \|\hat{x}\| = \|\hat{y}\| = 1$$

comprobado con vectores reales: 0.863245 = 0.863245

ÍNDICE EXACTO

```
index = faiss.IndexFlatIP(384)
index.add(chunk_vectors)
scores, ids = index.search(q, k)
```

búsqueda exhaustiva = exacta; igual a NumPy (verificado).

documento	unidad de la fuente
chunk	unidad que se indexa
índice	organiza y busca vectores
recuperador	política completa: k, qué se entrega

Se agrupan passages hasta ~target_words, con 1 de solape

EXP. 2 · TARGET_WORDS

condición	chunks	pal. media	tok. máx
small · 100	40	76.8	154
baseline · 180	20	131.2	242
large · 320	9	239.8	444

444 < 512: no hay truncación; se mide granularidad.

EJEMPLO REAL: D08 (6 PASSAGES) CON BASELINE

```
P1 P2 P3 P4 P5 P6
[P1 P2 P3 P4 P5]  D08-C01
            [P5 P6]  D08-C02
```

P5 aparece en dos chunks: conserva continuidad, pero repite texto y gasta lugares del top-k.

	variable modificada	fijo	métrica
Exp. 1	consulta: Q0 vs Q1 (LLM)	corpus, chunks 180, e5, FlatIP, k	schema_valid_rate, Recall@k
Exp. 2	target_words 100 / 180 / 320	corpus, Q0, qrels, overlap, e5, FlatIP	Recall@1/3/5 · principal: @3

Q1 casi copió a Q0; el descenso es un solo caso inválido

id	Q1 (LLM)	R@3 Q0	R@3 Q1
Q01	válida · copia de Q0	0.5	0.5
Q02	válida · copia de Q0	1.0	1.0
Q03	**inválida** · claves inventadas	1.0	**0.0**
Q04	válida · copia de Q0	0.5	0.5
Q05	válida · recorta «¿Cómo se mide»	1.0	1.0
Q06	válida · copia de Q0	1.0	1.0

MEAN RECALL@3

Q0

0.833

Q1 (PIPELINE)

0.667

SOLO UTILIZABLES

0.800 = 0.800

Q1 inválida no llega al índice: Recall = 0. Con JSON válido, los top-3 coinciden 3 de 3 con los de Q0. **No hay evidencia de que estructurar mejore la recuperación**; sí de que el contrato puede fallar.

Más contexto por chunk gana cobertura y pierde precisión

	R@1	R@3	R@5	prec@3
small	0.583	**0.833**	0.833	0.336
baseline	0.667	**0.833**	0.917	0.194
large	0.667	**0.917**	1.000	0.097

RECALL@3 POR CONSULTA

	Q01	Q02	Q03	Q04	Q05	Q06
small	.5	1	**.5**	1	1	1
baseline	.5	1	1	**.5**	1	1
large	.5	1	1	1	1	1

Q04 · 0.5 → 1.0 (SMALL, LARGE)

En baseline, dos chunks de D08 que se solapan en D08-P05 más uno de D02 desplazan a D01-P06.

Q03 · 0.5 → 1.0 (BASELINE, LARGE)

small: P02 en rank 1 pero P03 en otro chunk fuera del top-3. Con chunk grande van juntos, pero en rank 3 y 2.

SIN CAMBIO

Q02, Q05, Q06 (1.0) y Q01 (0.5).

0.833 → 0.917 es **medio caso de una consulta**. Con large hay 9 chunks de 5.7 passages: top-5 cubre más de la mitad del índice, por eso Recall@5 = 1.0 es casi trivial.

Un documento acapara el ranking y desplaza al otro

NECESIDAD

«¿Qué pasó con la volatilidad esperada del mercado en el peor día de la crisis del COVID en marzo de 2020?»

GOLD (2 DOCUMENTOS)

D01-P05 crónica 16-mar: VIX cierra en 82,69
D05-P05 doc VIX: récord de cierre 82,69

DÓNDE QUEDA EL CHUNK CON D05-P05

	rank	score	top-1
small (40)	**10**	0.8544	0.8723
baseline (20)	**9**	0.8479	0.8825
large (9)	**4**	0.8536	0.8908

```
top-5 small   D01 D01 D01 D01 D01
top-5 base    D01 D01 D01 D08 D03
```

La consulta comparte vocabulario con la crónica del COVID, así que **D01 acapara el top-k**. Los scores de e5 están en una banda estrecha (0.85–0.89): 0.002 decide el orden. El tamaño del chunk no lo arregla; haría falta **diversificar o reordenar** (Semana 5 en adelante) o mencionar el indicador en la consulta.

Lo que está respaldado y lo que todavía no

RESPALDADO POR ESTOS DATOS

- 6/6 parseables, **0/6** JSON exacto, **5/6** schema-valid
- Con JSON válido, Q1 copió Q0: sin mejora de recuperación
- Recall@3: 0.833 → 0.917, por una consulta (Q04)
- Precisión de evidencia: 0.336 → 0.097
- Q01: un documento desplaza al otro; no es chunking

LIMITACIONES

- 6 consultas, 50 passages: cada consulta pesa 0.167
- Qwen 0.5B: ignora «sin Markdown», intent siempre `risk_event`
- Corpus resumido por mí: léxico compartido con mis consultas
- Recall por passages cubiertos favorece chunks grandes
- Un encoder, índice exacto, sin intervalos de confianza

SIGUIENTE PASO

Modelo mayor o decoding con restricción para la consulta; qrels graduados y más consultas; diversificar o reordenar antes de entregar evidencia a un generador (Semana 5 en adelante).