

Vigilante de riesgo de mercado

Clasificación de una señal como low, medium o high con Qwen2.5-0.5B-Instruct y salida JSON validada con JSON Schema.

MODELO	CASOS	EXPERIMENTOS	MAX_NEW_TOKENS	SEED BASE
0.5B Qwen2.5-Instruct, CPU	8 señales reales, 3·2·3	3 prompt, contexto, decoding	192 en todas las condiciones	42 D1: seeds 42 a 46

ETIQUETAS

low

medium

high

SALIDA { label, confidence, reason }

Clasificar una señal de mercado en low, medium o high

Reduzco mi tesis (vigilante multiagente de riesgo de mercado) a una sola unidad: un LLM pequeño recibe tres indicadores de un activo y devuelve una alerta estructurada que se valida por código.

ENTRADA · SPY

Retorno a 5 días -12.54 %
Volatilidad 20d 76.95 %
Caída desde máx. -29.11 %



SALIDA ESPERADA · JSON

```
{ "label": "high", "confidence": 0.9,  
  "reason": "volatilidad 76.95 %, caída -29.11 %" }
```

PIPELINE

Datos

Yahoo Finance, 4
activos, 8 fechas

→ Regla de puntos
etiqueta de referencia

→ Prompt
tarea · entrada ·
contexto · contrato

→ Qwen2.5-0.5B
greedy o sampling

→ Validación
parse → schema →
correcto

→ Métricas
schema_valid,
accuracy, macro-F1

Exp. 1 · prompt

Exp. 2 · contexto

Exp. 3 · decoding

cada experimento cambia una sola variable

Retorno, volatilidad y caída desde el máximo

Se calculan con precios de cierre diarios. Ejemplo real: SPY el 16-mar-2020, crash por COVID-19.

1 · RETORNO A 5 DÍAS

$$R_5 = P_t / P_{t-5} - 1$$

P_t = 218.09 (16-mar)

P_{t-5} = 249.35 (9-mar)

R_5 = **-12.54 %**

Dirección. Cuánto cambió el precio en la última semana bursátil (5 ruedas).

Negativo = cayó.

2 · VOLATILIDAD DE 20 DÍAS

$$\sigma_{20} = \text{std}(r_{t-19..t}) \cdot \sqrt{252}$$

$r_i = P_i / P_{i-1} - 1$ (retorno diario)

std diaria = 4.85 %

$\sigma_{20} = 4.85 \cdot \sqrt{252} = \mathbf{76.95 \%}$

Dispersión. Cuánto oscila el precio. Se anualiza con $\sqrt{252}$ (ruedas por año): es la variación anual que tendría el activo si mantuviera el ritmo de los últimos 20 días.

3 · CAÍDA DESDE EL MÁXIMO DE 20D

$$DD_{20} = P_t / \text{máx}(P_{t-19..t}) - 1$$

máx 20d = 307.64 (19-feb)

P_t = 218.09

$DD_{20} = \mathbf{-29.11 \%}$

Profundidad. Qué tan lejos está el precio de su techo reciente (drawdown). 0 % = en máximos.

Régimen	Caso	R_5	σ_{20}	DD_{20}	Lectura
calma	KO · 30-abr-2021	-0.90 %	9.54 %	-1.15 %	precio casi plano, oscilación diaria de 0.6 %
estrés	SPY · 16-mar-2020	-12.54 %	76.95 %	-29.11 %	caída de 29 % en un mes, oscilación diaria de 4.85 %

Regla de puntos y los 8 casos reales

Indicador	0 pts	1 pt	2 pts
σ_{20}	< 15 %	15 a 25 %	$\geq$ 25 %
DD_{20}	> -5 %	-5 a -10 %	$\leq$ -10 %
R_5	> -3 %	-3 a -6 %	$\leq$ -6 %

TOTAL 0-1 low 2-3 medium 4-6 high

La etiqueta de referencia sale de esta regla determinista, fijada **antes** de correr el modelo. No la decide un LLM ni yo caso por caso. La misma regla se entrega al modelo como contexto C0.

Datos: Yahoo Finance (yfinance), cacheados en data/raw/. Ningún dato sintético.

Caso	Activo · fecha	R_5	σ_{20}	DD_{20}	pts	Ref.
L1	SPY · 2017-06-30	-0.55	7.17	-1.17	0+0+0	low
L2	GLD · 2019-04-30	0.90	7.45	-1.89	0+0+0	low
L3	KO · 2021-04-30	-0.90	9.54	-1.15	0+0+0	low
M1	SPY · 2024-08-05	-5.03	19.19	-8.41	1+1+1	medium
M2	SPY · 2023-03-13	-4.72	15.79	-6.91	1+1+1	medium
H1	SPY · 2020-03-16	-12.54	76.95	-29.11	2+2+2	high
H2	IWM · 2022-06-13	-9.17	34.14	-10.61	2+2+2	high
H3	SPY · 2025-04-08	-11.50	31.44	-13.72	2+2+2	high

Puntos en el orden σ_{20} + DD_{20} + R_5 . Valores en %. Eventos: M1 carry trade, M2 crisis SVB, H1 COVID-19, H2 venta de small caps, H3 aranceles.

Atención causal, logits y decoding

SEMANA 1 · TOKENS Y ATENCIÓN CAUSAL

1	$-\infty$	$-\infty$	$-\infty$
1	1	$-\infty$	$-\infty$
1	1	1	$-\infty$
1	1	1	1

Máscara M: la posición i solo atiende a $j \leq i$. El futuro recibe $-\infty$ y softmax le da peso 0.

prompt P1 (H1): **478** tokens · entrada: 70
cambio el último token →
Δ logits posiciones previas = **0.0**
Δ logits última posición = 16.07

SEMANA 2 · LOGITS → SOFTMAX → ELECCIÓN DEL TOKEN

$$p_i = \exp(z_i / T) / \sum_j \exp(z_j / T)$$

1er token de label (H1)	logit z	T = 0.3	T = 0.8	T = 1	T = 2
low	25.95	0.986	0.786	0.715	0.532
medium	24.65	0.013	0.154	0.194	0.277
high	23.90	0.001	0.060	0.092	0.191

Probabilidad renormalizada entre las 3 etiquetas. Sobre todo el vocabulario a T = 1: 0.71 / 0.19 / 0.09.

Greedy toma el token de mayor p; determinista.	Sampling sortea según p; depende de la seed. Top-p 0.9: núcleo de 2 tokens (low + medium); high queda fuera.	KV cache guarda K y V ya calculados. Mismo texto; 48 tokens: 14 s con caché, 150 s sin caché.
--	---	---

Prompt en secciones y contrato con JSON Schema

P0 · BASELINE

"Clasifica el riesgo de mercado (low, medium o high) de la siguiente señal y responde en JSON."
+ entrada + contexto

P1 · MEJORADO

TAREA · puntuar, sumar, convertir
ENTRADA · indicadores
CONTEXTO · política de riesgo
CONTRATO · claves exactas, sin texto extra

DATA/SCHEMA.JSON · DRAFT 2020-12

```
{
  "label": enum
    ["low","medium","high"],
  "confidence": number
    [0, 1],
  "reason": string
    [10, 500] caracteres,
  "required": las 3,
  "additionalProperties": false
}
```

TRES NIVELES DE VALIDEZ

Nivel	Fallo observado
1 Parseable json.loads	JSON sin cerrar por bucle repetitivo (2 de 40 con sampling)
2 Schema-valid jsonschema	P0 inventó las claves "Riesgo de Mercado"
3 Correcto label = referencia	H1: JSON válido con "low" y razón "riesgo muy alta"

SALIDA CRUDA

Qwen envuelve el JSON en un bloque ```json, así que json.loads exacto falla siempre (**parse_exact = 0**). El parser recupera el primer objeto {...} decodificable; luego valida el schema.

P0 contra P1: el formato mejora, la etiqueta no

CAMBIA **prompt** P0 → P1 FIJO modelo · 8 casos · contexto C0 · greedy · schema · max_new_tokens 192

Métrica	P0	P1
schema_valid_rate	0/8 = 0.000	8/8 = 1.000
accuracy	0.000	3/8 = 0.375
macro-F1	0.000	0.182
error ordinal medio	—	1.00
razón anclada en datos	—	7/8
clasifica siempre low	—	3/8 = 0.375

Con P1 el modelo respondió **low en los 8 casos**. Su accuracy iguala la de un clasificador constante, y el macro-F1 de 0.182 = (0.545 + 0 + 0) / 3 confirma que solo acierta una clase.

CASO FALLIDO · H1 (CRASH COVID-19, REFERENCIA = HIGH)

P0 → { "Riesgo de Mercado": "medium", ... }
JSON parseable, no schema-valid

P1 → { "label": "**low**", "confidence": 0.9,
"reason": "...una situación de riesgo
de mercado **muy alta.**" }
schema-valid, incorrecto y contradictorio

Lectura. El contrato de P1 arregla claves, tipos y rangos. No hace que el modelo aplique la regla de puntos: **schema-valid ≠ correcto**. P1 cambia varias cosas a la vez, por lo que el efecto se atribuye al conjunto.

C0 contra C1: la nota conflictiva no mueve la etiqueta

CAMBIA **contexto** C0 = política → C1 = política + nota que contradice los datos FIJO modelo · prompt P1 · 8 casos · greedy · schema

Métrica	C0	C1
schema_valid_rate	8/8	8/8
accuracy	3/8 = 0.375	3/8 = 0.375
macro-F1	0.182	0.182
etiquetas que cambian		0 de 8
razón anclada en datos	7/8	6/8
confianza de M1	0.7	0.9

H1 · NOTA C1: "EL MERCADO SE MUESTRA TRANQUILO Y ESTABLE"

C0 → "riesgo de mercado **muy alta**" label: **low**
C1 → "el mercado se muestra **tranquilo y estable**,
con una volatilidad de **76.95 %**"
label: **low**

Lectura. El modelo copia el lenguaje de la nota, incluso junto a un dato que la contradice. La etiqueta no cambia, pero con C0 ya decía low en los 8 casos: las notas hacia "bajo" no tenían margen, y en los 3 casos low la nota hacia "alto" tampoco la movió. Es un **efecto de piso**, no evidencia de robustez.

Greedy contra sampling: variabilidad y seeds compartidas

CAMBIA **decoding** D0 greedy → D1 sampling (T = 0.8, top-p = 0.9, top-k = 0, seeds 42–46) FIJO modelo · P1 · C0 · 8 casos · max_new_tokens 192

Métrica	D0 greedy	D1 sampling
muestras	8	40
schema_valid_rate	1.000	37/40 = 0.925
accuracy	0.375	13/40 = 0.325
macro-F1	0.182	0.241
estabilidad vs greedy	–	30/40 = 0.75
razones distintas por caso	1	4 a 5 de 5

ETIQUETAS POR SEED (8 CASOS CADA UNA)				
seed	low	medium	high	inválidas
42	7	0	0	1
43	8	0	0	0
44	8	0	0	0
45	7	0	0	1
46	0	7	0	1

Lectura. La misma seed produce el mismo número aleatorio en cada caso; como el primer token tiene casi la misma distribución (0.71 / 0.19 / 0.09), la seed 46 eligió medium en 7 de 8 casos. Las 5 seeds no son muestras independientes entre casos. High nunca salió: con top-p 0.9 quedó fuera del núcleo.

Un contrato explícito arregla el formato, no el criterio

LO QUE SOSTIENE LA EVIDENCIA

Formato. El contrato de P1 llevó schema_valid de 0/8 a 8/8.

Semántica. El modelo respondió low en 8/8 casos con greedy; acierta 3/8, igual que un clasificador constante.

Contexto. La nota conflictiva no cambió ninguna etiqueta pero sí contaminó las razones (7/8 → 6/8 ancladas).

Decoding. Sampling: 37/40 válidas y 75 % de estabilidad; añade variabilidad y algún JSON sin cerrar.

LO QUE NO SE PUEDE AFIRMAR

Que P1 sea mejor en general: son 8 casos, una corrida por condición y un modelo de 0.5B.

Que el modelo resista contexto conflictivo: ya respondía low a todo (efecto de piso).

Que las 5 seeds sean independientes entre casos: comparten el sorteo del primer token.

Resultados en otros mercados: 5 de 8 casos son SPY; la referencia depende de umbrales que fijé yo.

SIGUIENTE PASO HACIA EL SISTEMA COMPLETO

1 · Probar un modelo mayor y few-shot.

2 · Más casos con intervalos de confianza.

3 · Calcular indicadores y puntos en código; el LLM solo interpreta y justifica.

Fuentes, repositorio y cómo ejecutar

FUENTES PRIMARIAS

- [1] Vaswani et al. (2017). *Attention Is All You Need*. arXiv:1706.03762 — Transformer y atención causal.
- [2] Qwen Team (2024). *Qwen2.5 Technical Report*. arXiv:2412.15115 — modelo utilizado.
- [3] Holtzman et al. (2020). *The Curious Case of Neural Text Degeneration*. arXiv:1904.09751 — top-p.

FUENTES ADICIONALES

- [4] Fan et al. (2018). *Hierarchical Neural Story Generation*. arXiv:1805.04833 — top-k.
- [5] JSON Schema Draft 2020-12 — json-schema.org.
- [6] Yahoo Finance vía yfinance — procedencia de los precios.
- [7] Material del curso CC0F4, Semanas 1 a 3 (kapumota/CC-0F4).

REPOSITORIO

README.md · requirements.txt
Dockerfile · docker-compose.yml
notebook/PC1_riesgo_mercado.ipynb
src/ · data/ · prompts/
results/ · slides/PC1.pdf

EJECUTAR

```
docker compose up  
# abrir localhost:8888/lab
```

Cuaderno completo: ≈ 1 h en CPU (≈ 5 tokens/s). El cuaderno guarda las salidas. results/config_corrida.json registra revisión del modelo, versiones, hashes de prompts y decoding.